Diyabet Veri Seti Analiz Raporu

Bu rapor, temizlenmiş ve şeker parametreleri eksiksiz doldurulmuş olan veri setine ait demografik, klinik ve istatistiksel analizleri içermektedir.

- **Toplam Satır Sayısı:** 902
- **Toplam Sütun Sayısı:** 16

---

1. Eksik Veri (Null) Analizi ve Veri Filtreleme Aşamaları

Bu çalışma kapsamında veri seti iki aşamalı bir temizleme ve filtreleme sürecinden geçirilmiştir:

Veri Temizleme ve Eleme Aşamaları Tablosu:

Aşama	Uygulanan Filtre	Elenen Satır Sayısı	Kalan Satır Sayısı
Başlangıç	Orijinal Ham Veri Seti	-	43,460
1. Aşama	Şeker Ölçümleri Eksik Olanların Elenmesi (AKŞ, TKŞ 1, TKŞ 2, HbA1c null/0)	42,518	942
2. Aşama	Lipid Paneli ve Yaş Değerleri Eksik Olanların Elenmesi (Kolesterol, HDL, LDL, TG, Yaş null)	40	902

Nihai veri setinde (902 satır) hiçbir sütunda eksik veya boş değer kalmamıştır.



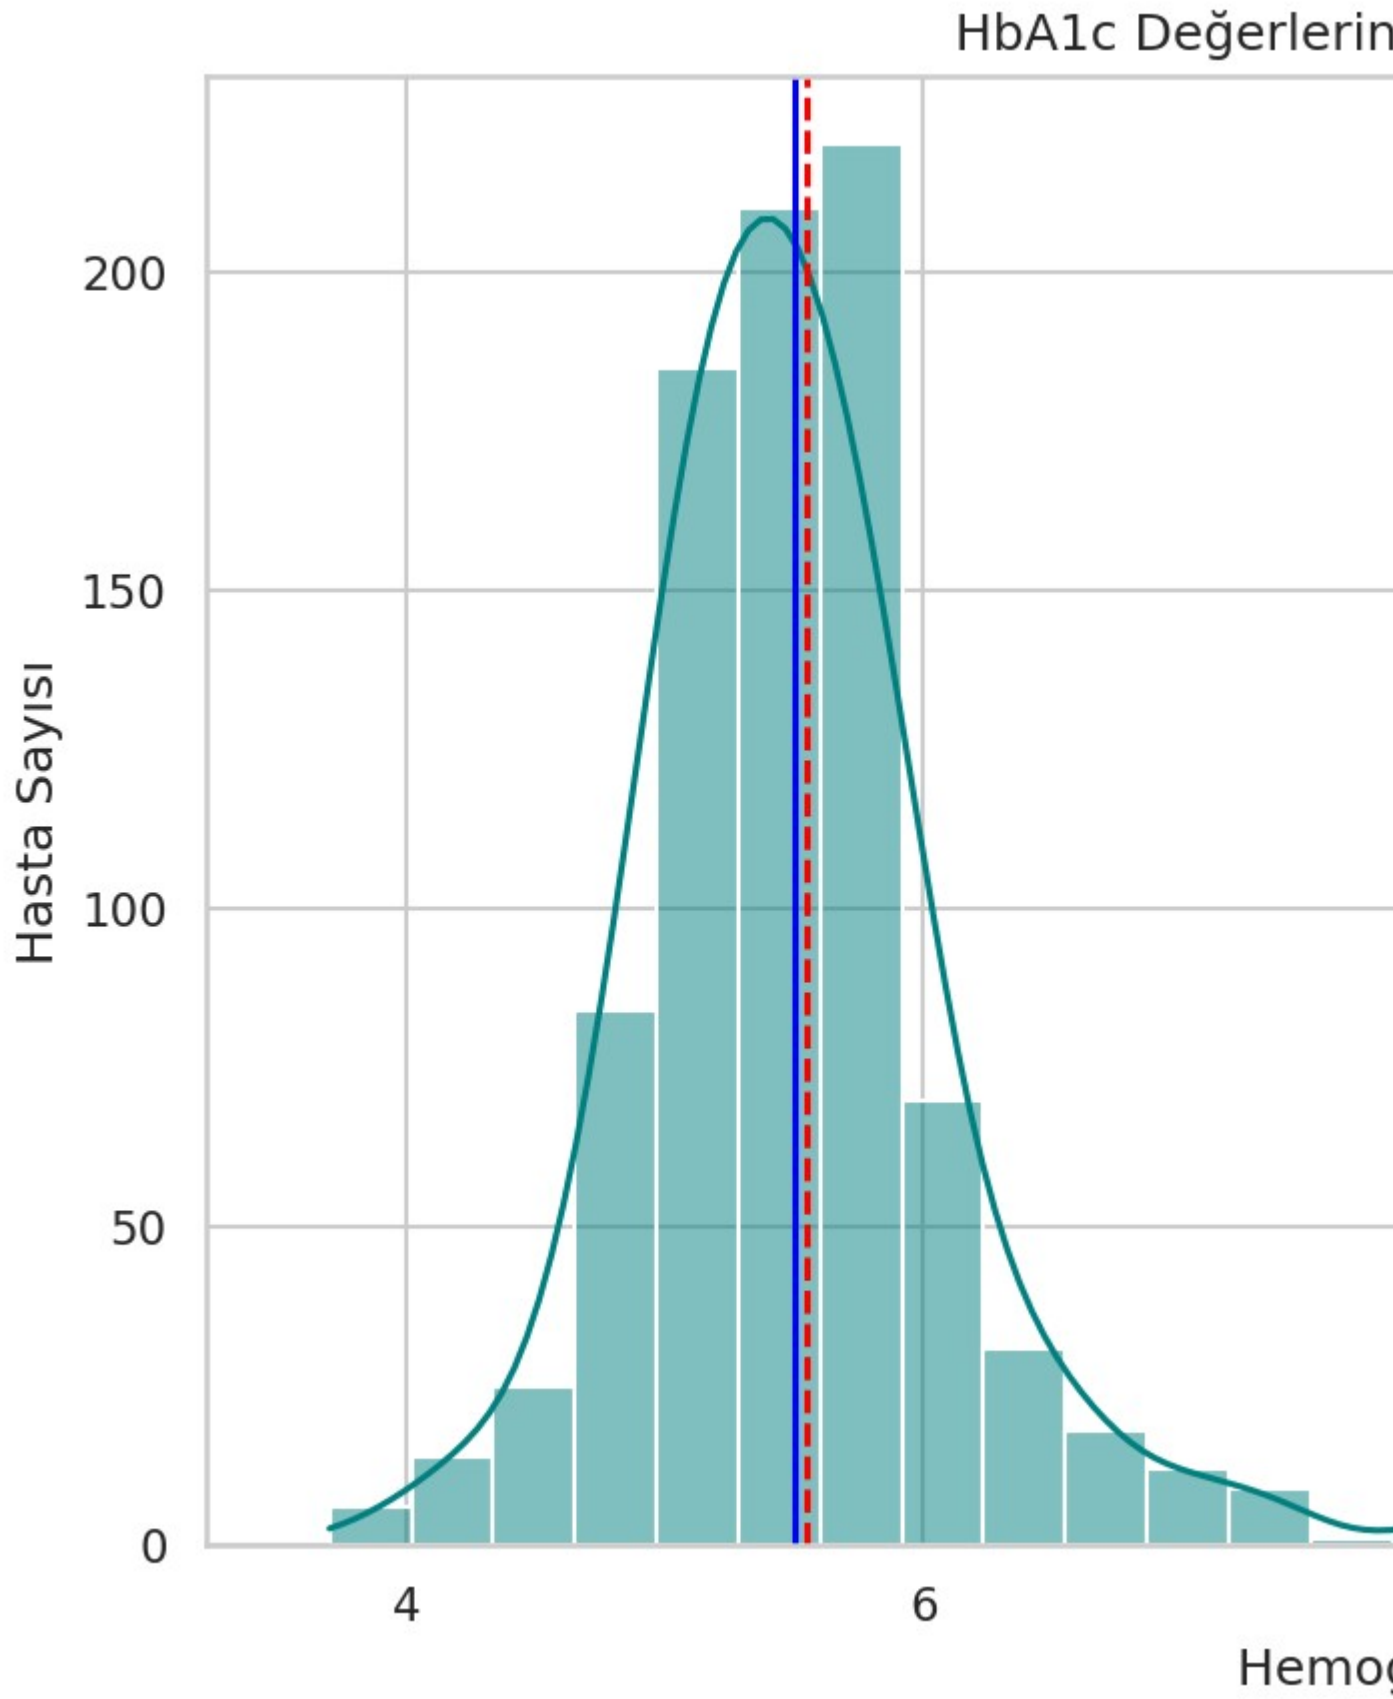
Eksik Veri Analizi Grafiği

1. Aşama Sonrası Şeker Ölçümleri Eksiksiz Olan Veri Kümesindeki Eksiklik Oranları (942 Satır):

Değişken Adı	Eksik Hücre Sayısı	Oran (%)
Yaş	0	%0.0
Cinsiyet	0	%0.0
Açlık Kan Şekeri (AKŞ)	0	%0.0
Tokluk Kan Şekeri (TKŞ) 1.Saat	0	%0.0
Tokluk Kan Şekeri (TKŞ) 2.Saat	0	%0.0
Hemoglobin (Hb A1c)	0	%0.0
Kolesterol (Total)	31	%3.3
Kolestrol (HDL)	32	%3.4
Kolestrol (LDL)	40	%4.3
Trigliserid	30	%3.2

2. HbA1c Dağılımı ve Risk Sınıfları

HbA1c değerleri, hastaların glisemik kontrol seviyelerini belirlemede en önemli parametredir.



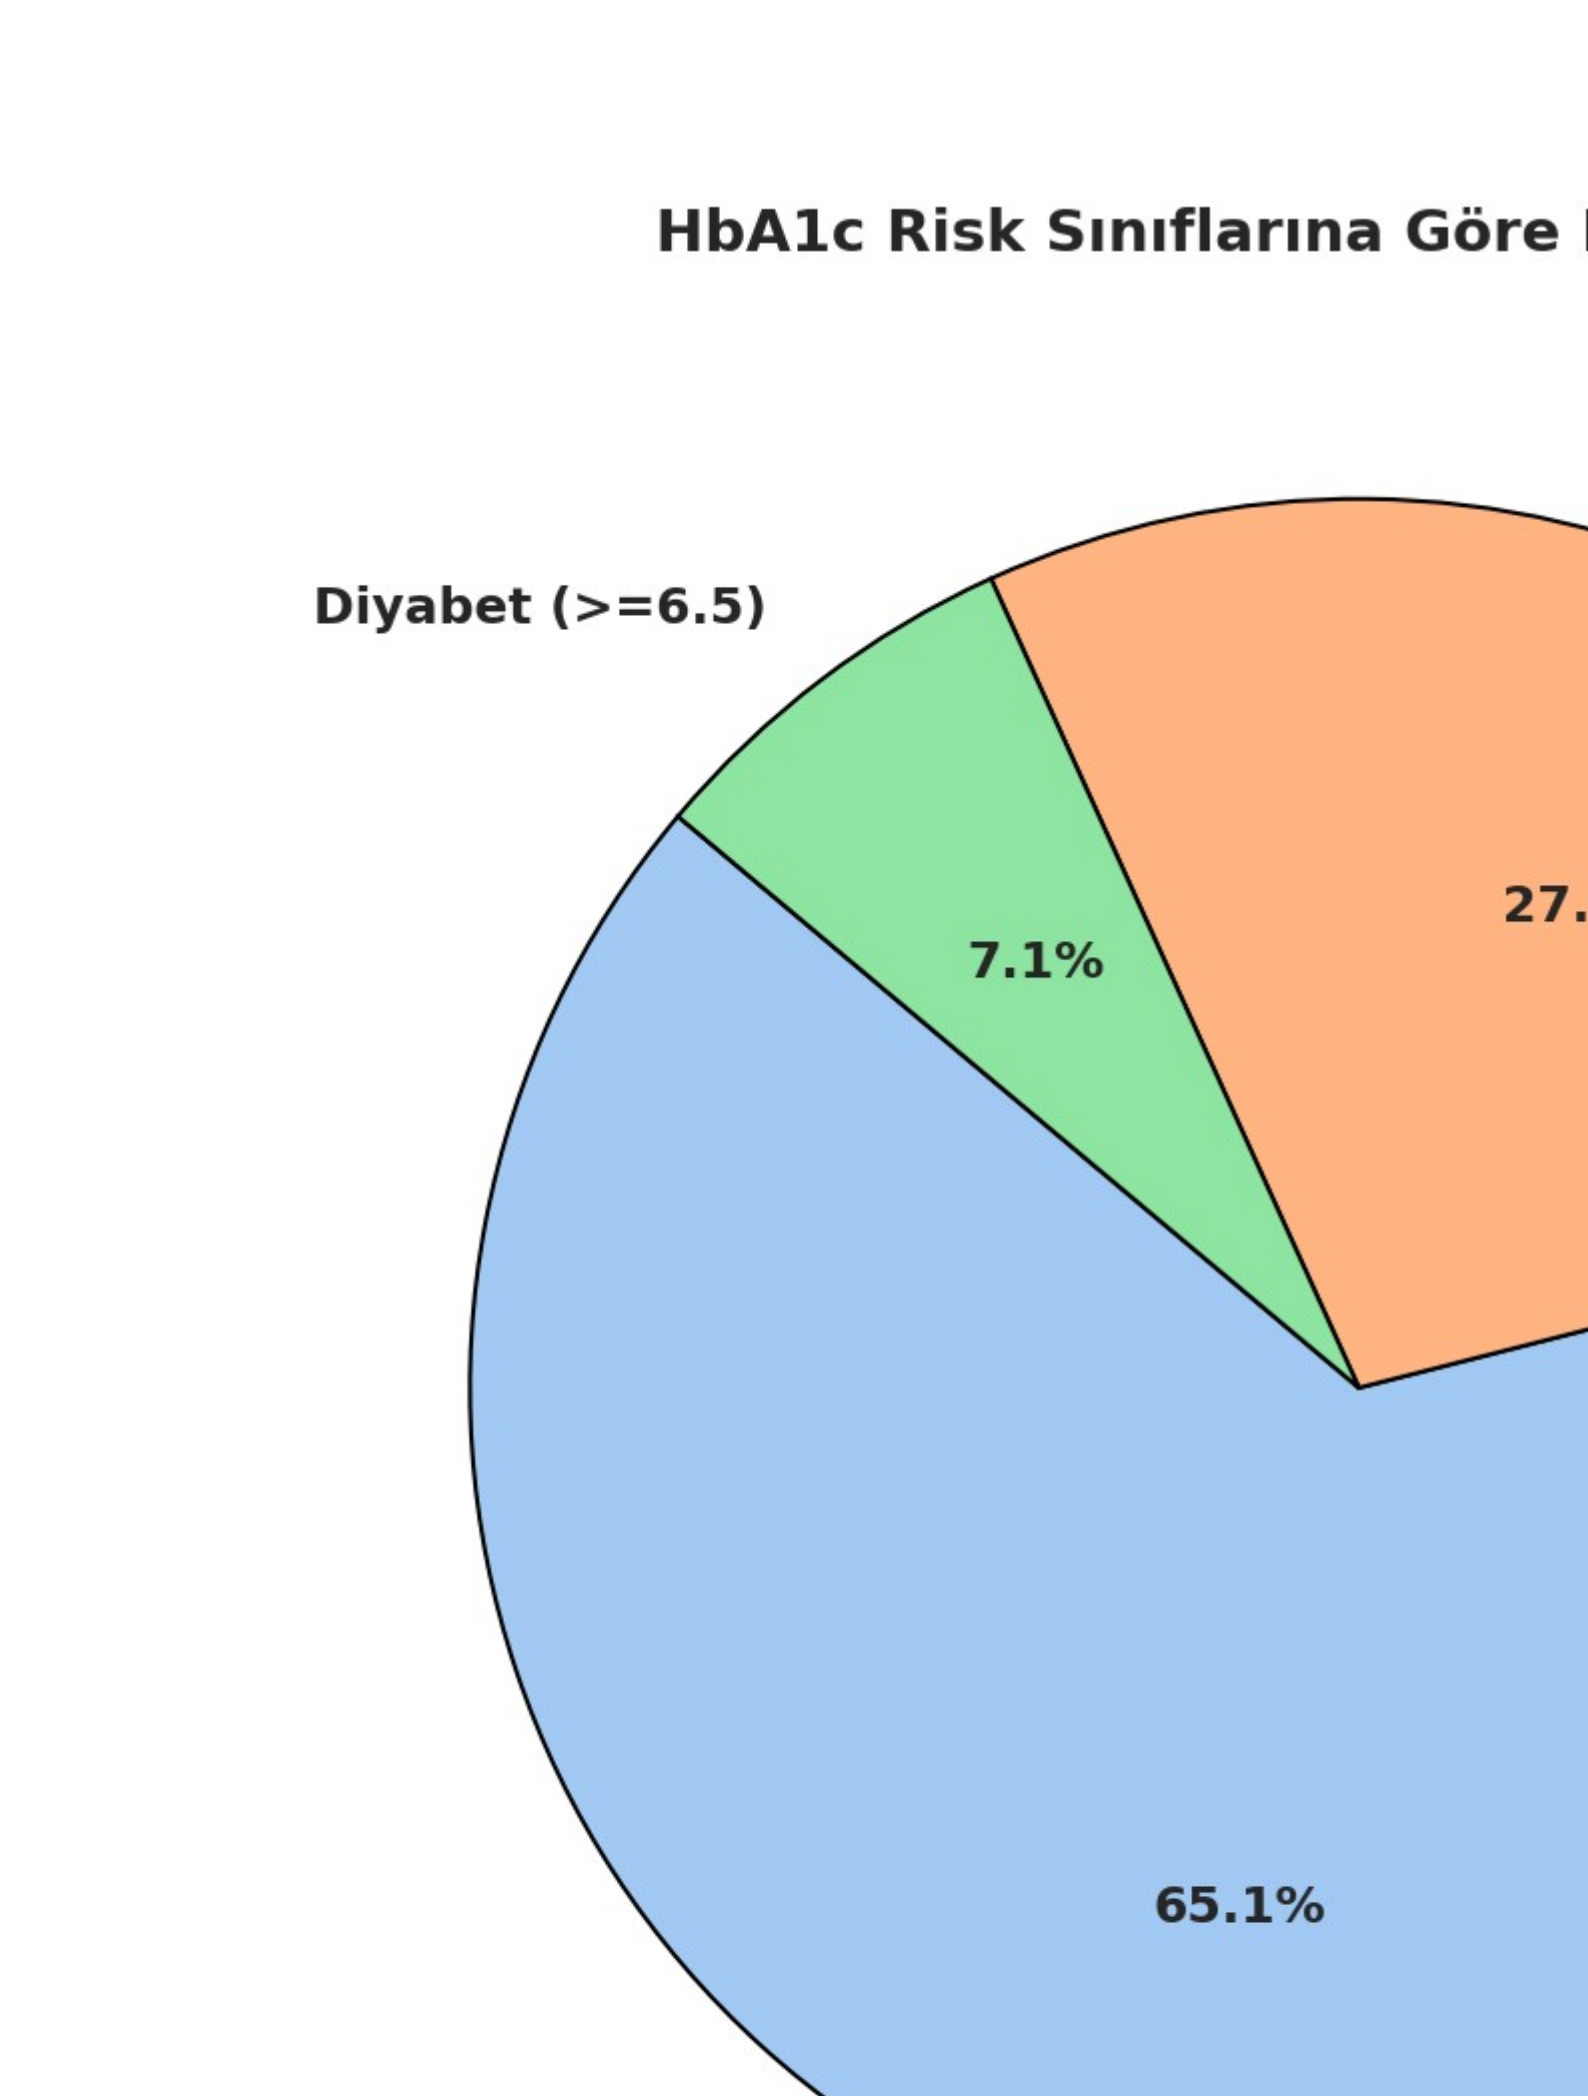
HbA1c Dağılımı

- **Ortalama HbA1c:** %5.54

- **Medyan HbA1c:** %5.50
- **En Düşük HbA1c:** %3.70
- **En Yüksek HbA1c:** %13.20

HbA1c Risk Sınıfları Dağılımı (ADA Kriterlerine Göre)

Amerikan Diyabet Birliği (ADA) standartlarına göre yapılan gruplandırma sonuçları aşağıdaki gibidir: * **Normal:** < %5.7 * **Prediyabet (Gizli Şeker):** %5.7 - %6.4 * **Diyabet (Şeker Hastalığı):** >= %6.5

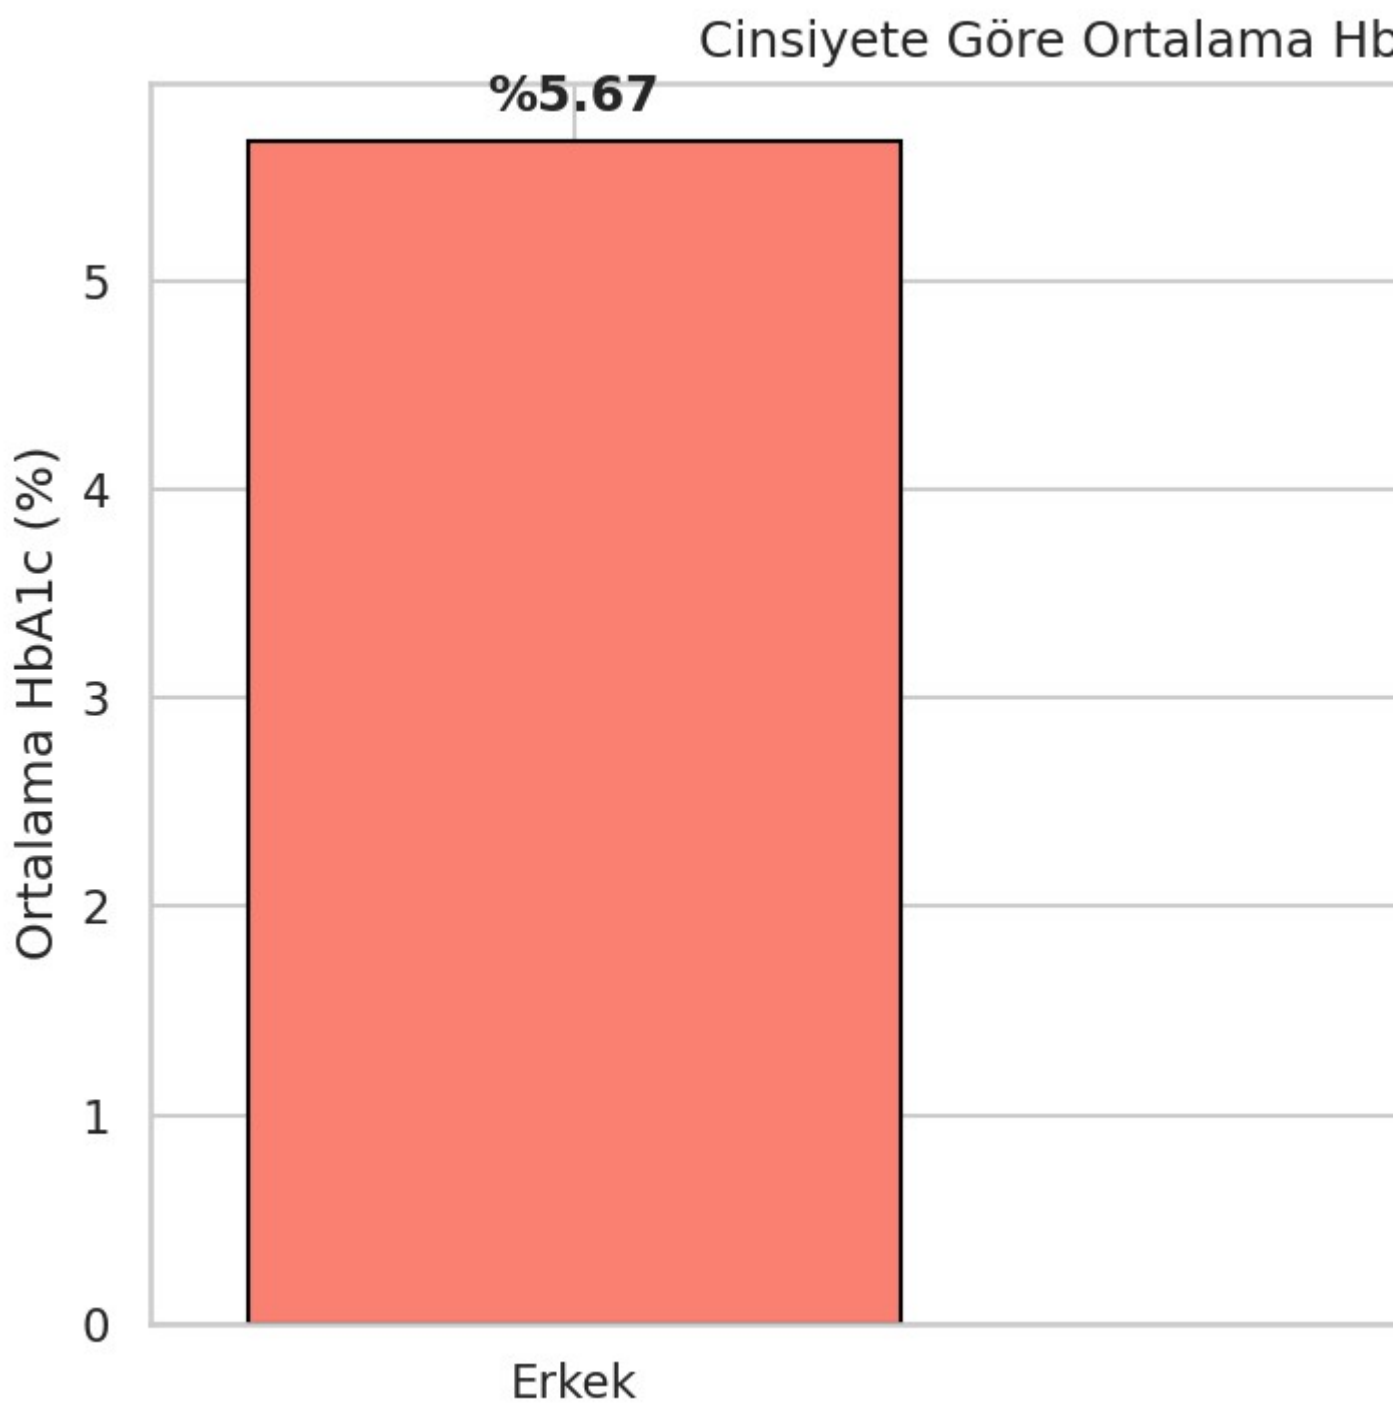

HbA1c Risk Sınıflarına Göre
Diyabet (>=6.5)
7.1%
27.
65.1%

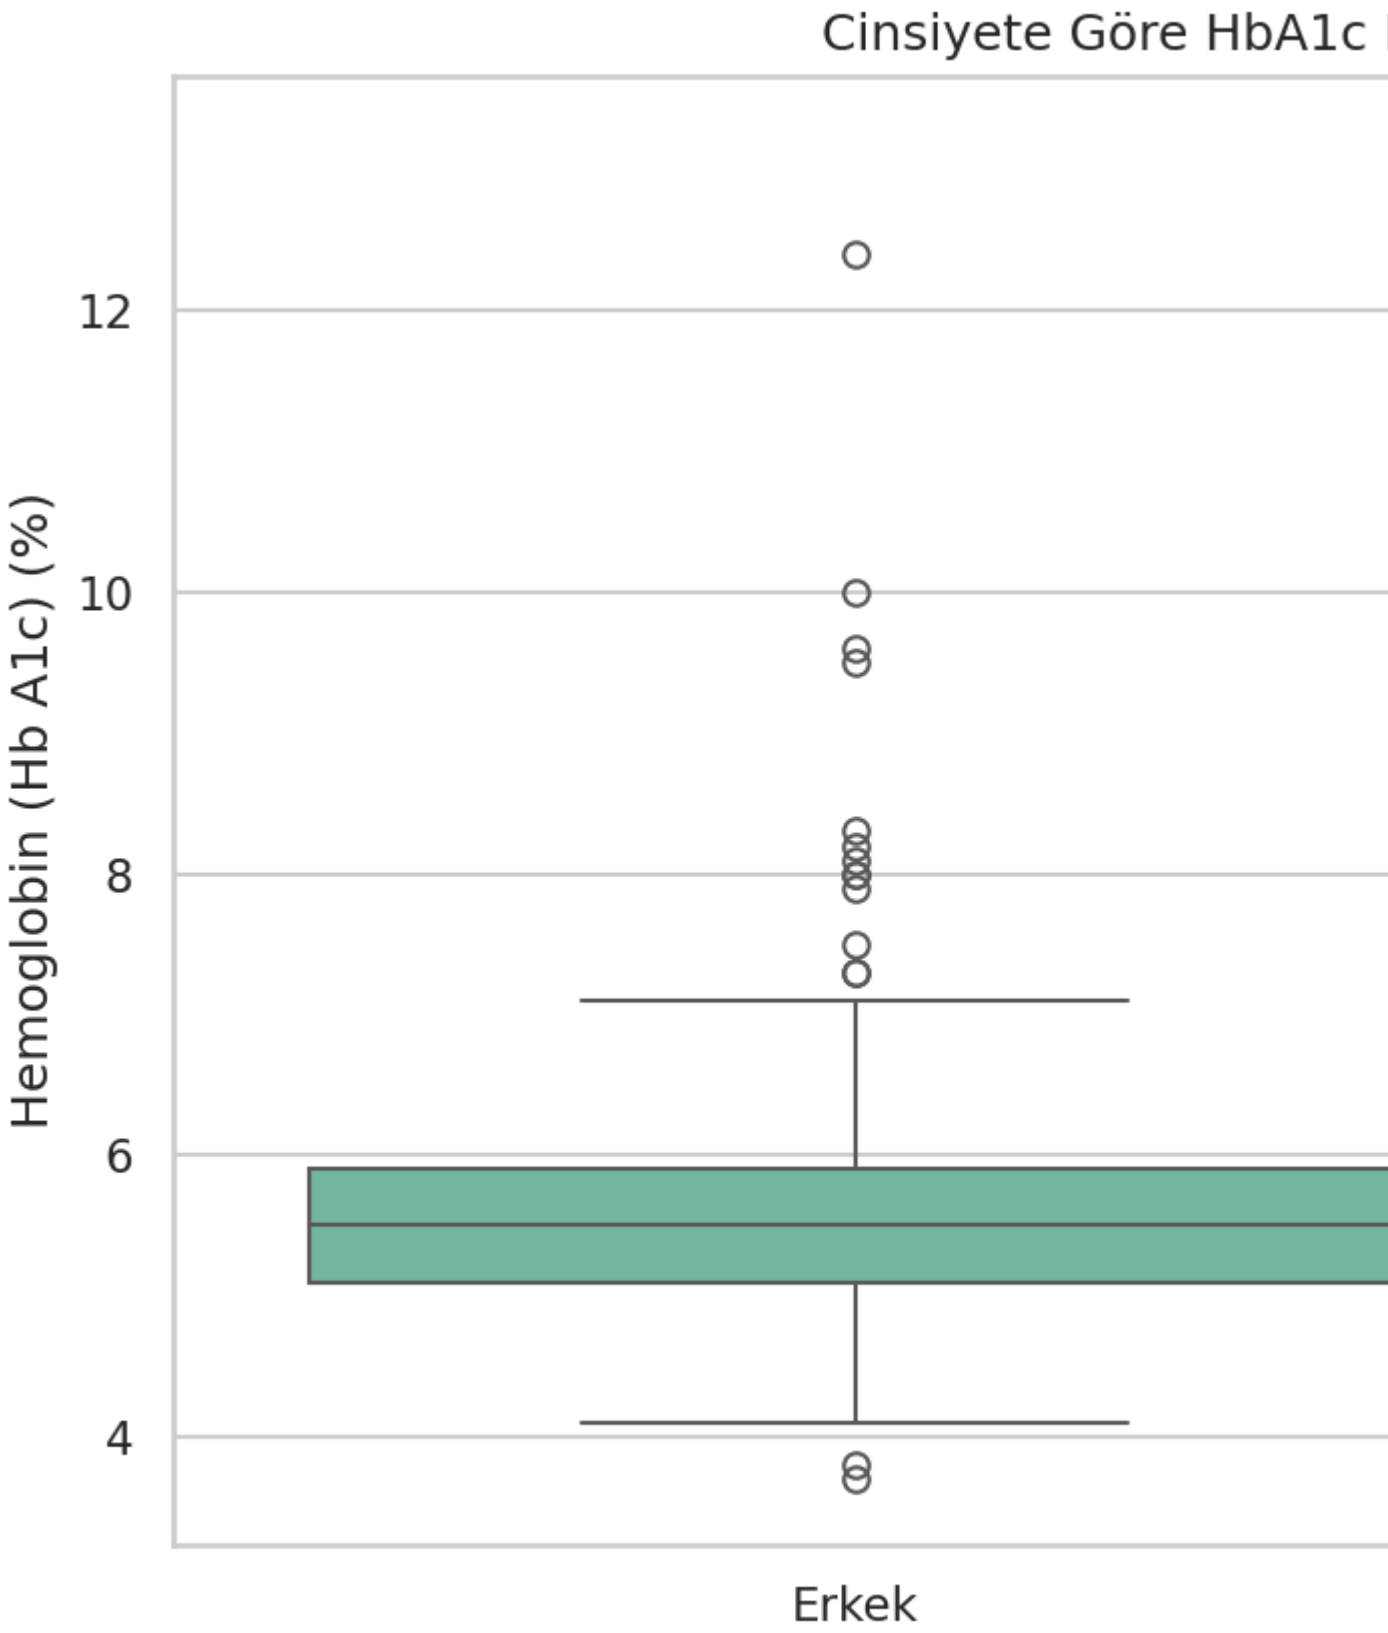
HbA1c Risk Sınıfları Dağılımı

Risk Sınıfı	Hasta Sayısı	Oran (%)	Ortalama AKŞ (mg/dL)	Ortalama TKŞ 2.Saat (mg/dL)
Normal	587	%65.1	89.5	97.3
Prediyabet	251	%27.8	100.0	123.4
Diyabet	64	%7.1	149.6	218.1

3. Cinsiyet Analizi

Veri setinde cinsiyete bağlı olarak şeker metabolizması parametrelerinin dağılımı incelenmiştir.





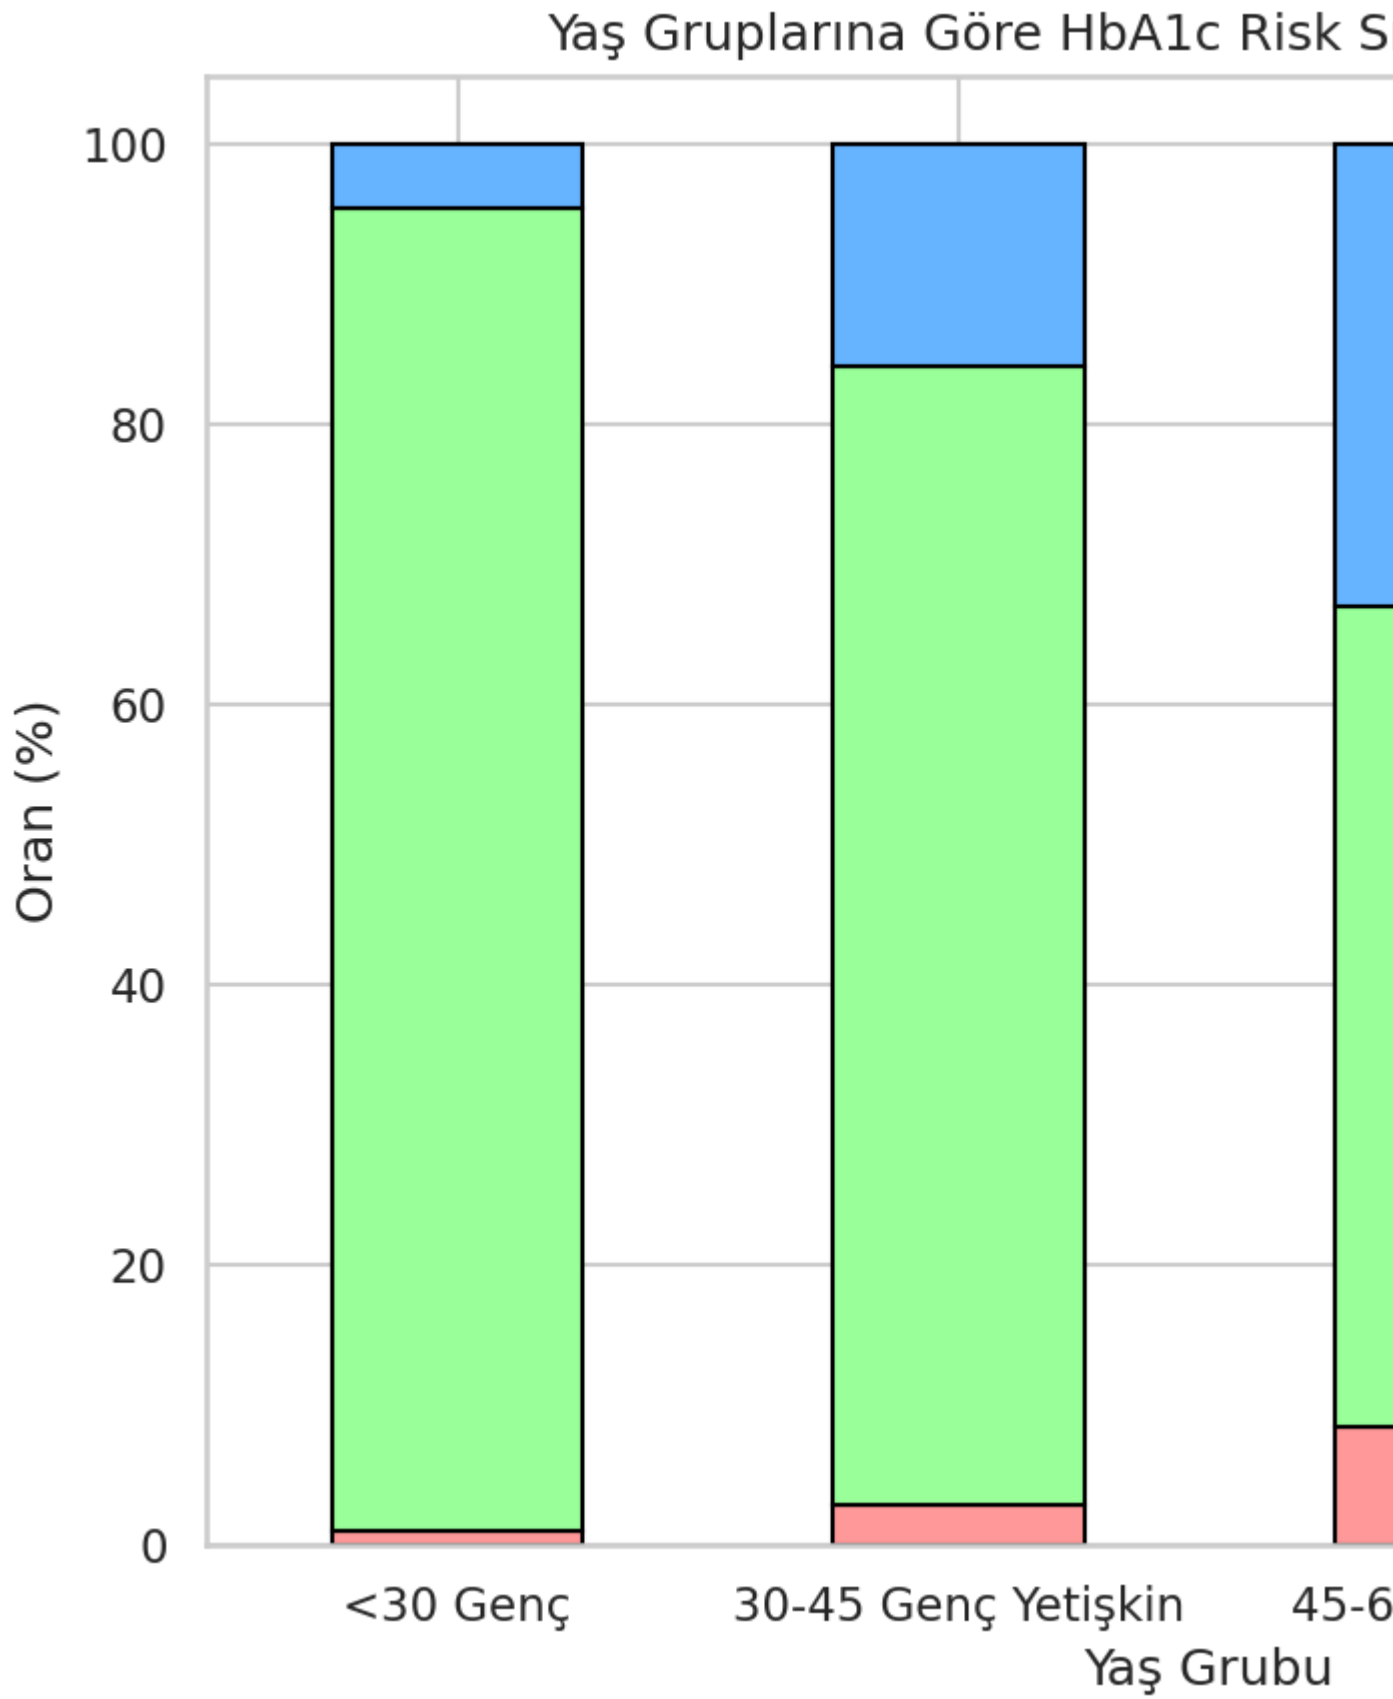
- **Kadın Hasta Sayısı:** 707 (%78.4)
- **Erkek Hasta Sayısı:** 195 (%21.6)

Cinsiyet Temelli Klinik İstatistikler

Cinsiyet	Ortalama Yaş	Ortalama HbA1c (%)	Ortalama AKŞ (mg/dL)	Ortalama TKŞ 2.Saat (mg/dL)
Kadın	50.2	%5.51	95.5	109.5
Erkek	50.3	%5.67	100.9	126.4

4. Yaş Gruplarına Göre HbA1c Risk Dağılımı

Diyabet ve gizli şeker riski, yaşla birlikte metabolizmadaki değişimlere bağlı olarak artış gösterir. Yaş gruplarına göre hastaların HbA1c risk sınıfları arasındaki dağılımı aşağıda gösterilmiştir:



Yaş Gruplarına Göre Risk Dağılımı

Yaş Grubu Bazında HbA1c Dağılımı (Sayısal ve Yüzdelik):

Yaş Grubu	Normal (<5.7)	Prediyabet (5.7-6.4)	Diyabet (>=6.5)	Toplam Hasta
<30 Genç	84 (%94.4)	4 (%4.5)	1 (%1.1)	89
30-45 Genç Yetişkin	196 (%81.3)	38 (%15.8)	7 (%2.9)	241
45-60 Orta Yaş	206 (%58.5)	116 (%33.0)	30 (%8.5)	352
60+ Yaşlı	101 (%45.9)	93 (%42.3)	26 (%11.8)	220

---

5. Korelasyon Analizi

HbA1c ile diğer klinik ve demografik özellikler arasındaki doğrusal ilişkilerin incelenmesi amacıyla korelasyon katsayıları hesaplanmıştır.

Özellikler Arası K

	Yaş	Cinsiyet	Açlık Kan Şekeri (AKŞ)	Hemoglobin (Hb A1c)
Yaş	1.00	0.00	0.19	0.3
Cinsiyet	0.00	1.00	0.08	0.0
Açlık Kan Şekeri (AKŞ)	0.19	0.08	1.00	0.6
Hemoglobin (Hb A1c)	0.33	0.09	0.66	1.0
Kolesterol (Total)	0.14	0.16	0.01	0.0
Kolestrol (HDL)	0.06	-0.37	-0.13	0.1
Kolestrol (LDL)	0.09	0.08	0.01	0.0
Tokluk Kan Şekeri (TKŞ) 1.Saat	0.29	0.14	0.73	0.6
Tokluk Kan Şekeri (TKŞ) 2.Saat	0.25	0.14	0.78	0.7
Trigliserid	0.16	0.13	0.18	0.2
TG_HDL_Orani	0.09	0.26	0.19	0.2
LDL_HDL_Orani	0.01	0.20	0.07	0.1
AKS_TKS_Orani	-0.19	0.13	0.15	0.3
Glisemik_Ortalama	0.27	0.14	0.87	0.7

Yaş

Cinsiyet

Şekeri (AKŞ)

bin (Hb A1c)

Korelasyon Isı Haritası

HbA1c ile En Çok İlişkili Özellikler (Sıralı):

Değişken (Feature)	Pearson Korelasyon Katsayısı
Hemoglobin (Hb A1c)	1.000
Glisemik_Ortalama	0.724
Tokluk Kan Şekeri (TKŞ) 2.Saat	0.698
Tokluk Kan Şekeri (TKŞ) 1.Saat	0.662
Açlık Kan Şekeri (AKŞ)	0.659
Yaş	0.331
TG_HDL_Orani	0.290
Trigliserid	0.266
LDL_HDL_Orani	0.112
Cinsiyet	0.085
Kolesterol (Total)	-0.001
Kolestrol (LDL)	-0.010
Kolestrol (HDL)	-0.186
AKS_TKS_Orani	-0.303

---

6. Makine Öğrenmesi (Machine Learning) Model Sonuçları ve Aşırı Öğrenme (Overfitting) Analizi

Bu bölümde; veri setinin normal (temel) ve gelişmiş (özellik mühendisliği uygulanmış) halleri üzerinde, hem varsayılan hem de hiperparametre ayarlı (GridSearchCV + Nested 5-Fold Cross Validation) modellerimizin başarımları ve aşırı öğrenme (overfitting) farkları karşılaştırılmıştır.

Bu tablo; ham veri, özellik mühendisliği yapılmış veri ve hiperparametre ayarlarının (tuning) model performansları ile overfitting durumları üzerindeki etkilerini bir arada göstermektedir.

Model	Deney Senaryosu	Eğitim R^2 (Train)	Doğrulama R^2 (Val)	Fark (Gap R^2)	Doğrulama MSE	Durum Analizi
Random_Forest	1. Temel Veri (Varsayılan)	0.8686	0.4842	0.3844	0.3055	⚠ Yüksek Overfitting
Gradient_Boosting	1. Temel Veri (Varsayılan)	0.9021	0.4837	0.4184	0.3038	⚠ Yüksek Overfitting
XGBoost	**1. Temel Veri (Varsayılan)**	**0.8686**	**0.5339**	**0.3347**	**0.2778**	⚠ **Yüksek Overfitting**
Artificial_Neural_Network	1. Temel Veri (Varsayılan)	0.7774	0.1430	0.6344	0.5809	⚠ Yüksek Overfitting
AdaBoost	1. Temel Veri (Varsayılan)	0.7720	0.5000	0.2720	0.2999	⚠ Yüksek Overfitting
Decision_Tree	1. Temel Veri (Varsayılan)	0.6843	0.3379	0.3464	0.3914	⚠ Yüksek Overfitting
Random_Forest	2. Gelişmiş Veri (Varsayılan)	0.8745	0.5014	0.3731	0.2969	⚠ Yüksek Overfitting
Gradient_Boosting	2. Gelişmiş Veri (Varsayılan)	0.9139	0.5093	0.4045	0.2883	⚠ Yüksek Overfitting
XGBoost	2. Gelişmiş Veri (Varsayılan)	0.8815	0.5271	0.3544	0.2801	⚠ Yüksek Overfitting
Artificial_Neural_Network	2. Gelişmiş Veri (Varsayılan)	0.8091	-0.2103	1.0194	0.8529	⚠ Yüksek

Model	Deney Senaryosu	Eğitim R^2 (Train)	Doğrulama R^2 (Val)	Fark (Gap R^2)	Doğrulama MSE	Durum Analizi
						Overfitting
AdaBoost	**2. Gelişmiş Veri (Varsayılan)**	**0.7807**	**0.5332**	**0.2476**	**0.2756**	**Hafif Overfitting**
Decision_Tree	2. Gelişmiş Veri (Varsayılan)	0.6895	0.3087	0.3808	0.4088	⚠ Yüksek Overfitting
Random_Forest	3. Temel Veri (Hiperparametre Ayarlı)	0.6904	0.4849	0.2055	0.3147	Hafif Overfitting
Gradient_Boosting	3. Temel Veri (Hiperparametre Ayarlı)	0.7181	0.4916	0.2265	0.3046	Hafif Overfitting
XGBoost	**3. Temel Veri (Hiperparametre Ayarlı)**	**0.7343**	**0.5493**	**0.1849**	**0.2689**	**Hafif Overfitting**
Artificial_Neural_Network	3. Temel Veri (Hiperparametre Ayarlı)	0.6257	0.4361	0.1896	0.3661	Hafif Overfitting
AdaBoost	3. Temel Veri (Hiperparametre Ayarlı)	0.7532	0.5024	0.2508	0.2947	⚠ Yüksek Overfitting
Decision_Tree	3. Temel Veri (Hiperparametre Ayarlı)	0.6259	0.3324	0.2935	0.3929	⚠ Yüksek Overfitting
Random_Forest	4. Gelişmiş Veri (Hiperparametre Ayarlı)	0.7044	0.4964	0.2080	0.3061	Hafif Overfitting
Gradient_Boosting	4. Gelişmiş Veri (Hiperparametre Ayarlı)	0.7118	0.4893	0.2225	0.3078	Hafif Overfitting
XGBoost	**4. Gelişmiş Veri (Hiperparametre Ayarlı)**	**0.7502**	**0.5498**	**0.2004**	**0.2693**	**Hafif Overfitting**
Artificial_Neural_Network	4. Gelişmiş Veri (Hiperparametre Ayarlı)	0.6449	0.4082	0.2368	0.3891	Hafif Overfitting
AdaBoost	4. Gelişmiş Veri	0.7440	0.5147	0.2292	0.2856	Hafif

Model	Deney Senaryosu	Eğitim R^2 (Train)	Doğrulama R^2 (Val)	Fark (Gap R^2)	Doğrulama MSE	Durum Analizi
	(Hiperparametre Ayarlı)					Overfitting
Decision_Tree	4. Gelişmiş Veri (Hiperparametre Ayarlı)	0.6439	0.3236	0.3204	0.3993	⚠ Yüksek Overfitting

7. Tekil Tabakalı Bölme Sonuçları (Stratified Train-Test Split)

Hiperparametre optimizasyonunun tekil bir eğitim-test bölmesindeki etkilerini doğrulamak amacıyla yapılan deney sonuçları aşağıda derlenmiştir:

Bu tablo; train-test bölünmesi sırasında **StratifiedShuffleSplit (Tabakalı Tekil Bölme)** kullanıldığında elde edilen train/test sonuçlarını karşılaştırmaktadır.

Model	Deney Senaryosu	Eğitim R^2 (Train)	Test R^2 (Test)	Fark (Gap R^2)	Test MSE	Durum Analizi
Random_Forest	1. Temel Veri (Varsayılan - Tabakalı)	0.9427	0.5142	0.4285	0.2559	⚠ Yüksek Overfitting
Gradient_Boosting	1. Temel Veri (Varsayılan - Tabakalı)	0.8610	0.4852	0.3757	0.2712	⚠ Yüksek Overfitting
XGBoost	1. Temel Veri (Varsayılan - Tabakalı)	0.9995	0.3802	0.6193	0.3265	⚠ Yüksek Overfitting
Artificial_Neural_Network	1. Temel Veri (Varsayılan - Tabakalı)	0.7106	0.4971	0.2134	0.2649	Hafif Overfitting
AdaBoost	**1. Temel Veri (Varsayılan - Tabakalı)**	**0.7351**	**0.5149**	**0.2201**	**0.2556**	**Hafif Overfitting**
Decision_Tree	1. Temel Veri (Varsayılan - Tabakalı)	1.0000	0.1114	0.8886	0.4682	⚠ Yüksek Overfitting
Random_Forest	2. Gelişmiş Veri (Varsayılan - Tabakalı)	0.9422	0.5449	0.3973	0.2398	⚠ Yüksek Overfitting
Gradient_Boosting	2. Gelişmiş Veri (Varsayılan - Tabakalı)	0.8708	0.4605	0.4102	0.2842	⚠ Yüksek Overfitting
XGBoost	2. Gelişmiş Veri (Varsayılan - Tabakalı)	0.9998	0.4322	0.5677	0.2992	⚠ Yüksek Overfitting
Artificial_Neural_Network	**2. Gelişmiş Veri (Varsayılan - Tabakalı)**	**0.7654**	**0.5457**	**0.2196**	**0.2393**	**Hafif Overfitting**
AdaBoost	2. Gelişmiş Veri	0.7528	0.5211	0.2317	0.2523	Hafif

Model	Deney Senaryosu	Eğitim R^2 (Train)	Test R^2 (Test)	Fark (Gap R^2)	Test MSE	Durum Analizi
	(Varsayılan - Tabakalı)					Overfitting
Decision_Tree	2. Gelişmiş Veri (Varsayılan - Tabakalı)	1.0000	0.0965	0.9035	0.4760	⚠ Yüksek Overfitting
Random_Forest	3. Temel Veri (Tuned - Tabakalı)	0.6568	0.5512	0.1056	0.2364	Dengeli / Stabil Model
Gradient_Boosting	3. Temel Veri (Tuned - Tabakalı)	0.7292	0.5280	0.2013	0.2487	Hafif Overfitting
XGBoost	**3. Temel Veri (Tuned - Tabakalı)**	**0.7710**	**0.5747**	**0.1962**	**0.2241**	**Hafif Overfitting**
Artificial_Neural_Network	3. Temel Veri (Tuned - Tabakalı)	0.6346	0.5431	0.0915	0.2407	Dengeli / Stabil Model
AdaBoost	3. Temel Veri (Tuned - Tabakalı)	0.7535	0.5126	0.2409	0.2568	Hafif Overfitting
Decision_Tree	3. Temel Veri (Tuned - Tabakalı)	0.5978	0.4600	0.1378	0.2845	Hafif Overfitting
Random_Forest	**4. Gelişmiş Veri (Tuned - Tabakalı)**	**0.6581**	**0.5635**	**0.0946**	**0.2300**	**Dengeli / Stabil Model**
Gradient_Boosting	4. Gelişmiş Veri (Tuned - Tabakalı)	0.7374	0.5356	0.2019	0.2447	Hafif Overfitting
XGBoost	4. Gelişmiş Veri (Tuned - Tabakalı)	0.7778	0.5419	0.2359	0.2413	Hafif Overfitting
Artificial_Neural_Network	4. Gelişmiş Veri (Tuned - Tabakalı)	0.6488	0.5539	0.0949	0.2350	Dengeli / Stabil Model
AdaBoost	4. Gelişmiş Veri (Tuned - Tabakalı)	0.7957	0.5225	0.2732	0.2516	⚠ Yüksek Overfitting
Decision_Tree	4. Gelişmiş Veri (Tuned - Tabakalı)	0.6065	0.5157	0.0908	0.2551	Dengeli / Stabil Model

8. Örnek Ağırlıklandırma (Sample Weighting) Sonuçları

Diyabetik hastaların (uç değerlerin) tahmin hata payını düşürmek amacıyla diyabetik hastalara 5 kat, prediyabetiklere 2 kat ceza ağırlığı uygulanarak koşturulan deneylerin sonuçları aşağıda karşılaştırılmıştır:

A) Tekil Tabakalı Bölme Üzerinde Ağırlıklandırma Sonuçları:

Tekil Tabakalı Ağırlıklı Bölme Master Karşılaştırma Sonuçları

Bu tablo; train-test bölünmesi sırasında diyabetik hastalara 5 kat, prediyabetiklere 2 kat ceza ağırlığı verildiğinde elde edilen train/test sonuçlarını karşılaştırmaktadır.

Model	Deney Senaryosu	Eğitim R^2 (Train)	Test R^2 (Test)	Fark (Gap R^2)	Test MSE	Diyabetik Test MAE	Durum Analizi
Random_Forest	3. Temel Veri (Weighted - Tabakalı)	0.6938	0.5306	0.1632	0.2473	0.5178	Hafif Overfitting
Gradient_Boosting	3. Temel Veri (Weighted - Tabakalı)	0.8144	0.4504	0.3641	0.2896	0.6264	⚠ Yüksek Overfitting
XGBoost	3. Temel Veri (Weighted - Tabakalı)	0.7766	0.4998	0.2768	0.2635	0.5767	⚠ Yüksek Overfitting
Artificial_Neural_Network	**3. Temel Veri (Weighted - Tabakalı)**	**0.6346**	**0.5431**	**0.0915**	**0.2407**	**0.8182**	**Dengeli / Stabil Model**
AdaBoost	3. Temel Veri (Weighted - Tabakalı)	0.7810	0.5098	0.2712	0.2583	0.6342	⚠ Yüksek Overfitting
Decision_Tree	3. Temel Veri (Weighted - Tabakalı)	0.6343	0.2814	0.3529	0.3786	0.7027	⚠ Yüksek Overfitting

Model	Deney Senaryosu	Eğitim R^2 (Train)	Test R^2 (Test)	Fark (Gap R^2)	Test MSE	Diyabetik Test MAE	Durum Analizi
Random_Forest	4. Gelişmiş Veri (Weighted - Tabakalı)	0.7037	0.5413	0.1623	0.2416	0.4913	Hafif Overfitting
Gradient_Boosting	4. Gelişmiş Veri (Weighted - Tabakalı)	0.8202	0.4769	0.3433	0.2756	0.6835	⚠ Yüksek Overfitting
XGBoost	4. Gelişmiş Veri (Weighted - Tabakalı)	0.8159	0.5140	0.3019	0.2560	0.6535	⚠ Yüksek Overfitting
Artificial_Neural_Network	**4. Gelişmiş Veri (Weighted - Tabakalı)**	**0.6488**	**0.5539**	**0.0949**	**0.2350**	**0.7267**	**Dengeli / Stabil Model**
AdaBoost	4. Gelişmiş Veri (Weighted - Tabakalı)	0.7853	0.5083	0.2770	0.2591	0.6442	⚠ Yüksek Overfitting
Decision_Tree	4. Gelişmiş Veri (Weighted - Tabakalı)	0.6367	0.4009	0.2359	0.3156	0.6332	Hafif Overfitting

B) K-Fold Çapraz Doğrulama Üzerinde Ağırlıklandırma Sonuçları:

Bu tablo; Nested 5-Fold Cross Validation bölünmesi sırasında diyabetik hastalara 5 kat, prediyabetiklere 2 kat ceza ağırlığı verildiğinde elde edilen ortalama train/validation sonuçlarını karşılaştırmaktadır.

Model	Deney Senaryosu	Eğitim R^2 (Train)	Doğrulama R^2 (Val)	Fark (Gap R^2)	Doğrulama MSE	Diyabetik MAE	Durum Analizi
Random_Forest	5. Temel Veri (Weighted - K-Fold)	0.6819	0.4831	0.1987	0.3139	0.8784	Hafif Overfitting
Gradient_Boosting	5. Temel Veri (Weighted - K-Fold)	0.7149	0.4398	0.2752	0.3391	0.9087	⚠ Yüksek Overfitting
XGBoost	**5. Temel Veri**	**0.7769**	**0.5256**	**0.2512**	**0.2817**	**0.8425**	**⚠ Yüksek**

Model	Deney Senaryosu	Eğitim R^2 (Train)	Doğrulama R^2 (Val)	Fark (Gap R^2)	Doğrulama MSE	Diyabetik MAE	Durum Analizi
	(Weighted - K-Fold)						**Overfitting**
Artificial_Neural_Network	5. Temel Veri (Weighted - K-Fold)	0.6257	0.4361	0.1896	0.3661	0.9956	Hafif Overfitting
AdaBoost	5. Temel Veri (Weighted - K-Fold)	0.7552	0.4584	0.2968	0.3283	0.8131	⚠ Yüksek Overfitting
Decision_Tree	5. Temel Veri (Weighted - K-Fold)	0.6091	0.3285	0.2807	0.3968	0.9651	⚠ Yüksek Overfitting
Random_Forest	6. Gelişmiş Veri (Weighted - K-Fold)	0.7035	0.4890	0.2145	0.3107	0.8838	Hafif Overfitting
Gradient_Boosting	6. Gelişmiş Veri (Weighted - K-Fold)	0.7547	0.4704	0.2843	0.3179	0.8675	⚠ Yüksek Overfitting
XGBoost	6. Gelişmiş Veri (Weighted - K-Fold)	0.7824	0.4970	0.2854	0.2972	0.8549	⚠ Yüksek Overfitting
Artificial_Neural_Network	6. Gelişmiş Veri (Weighted - K-Fold)	0.6449	0.4082	0.2368	0.3891	0.9912	Hafif Overfitting
AdaBoost	**6. Gelişmiş Veri (Weighted - K-Fold)**	**0.7736**	**0.5370**	**0.2366**	**0.2749**	**0.8207**	**Hafif Overfitting**
Decision_Tree	6. Gelişmiş Veri (Weighted - K-Fold)	0.6446	0.2928	0.3518	0.4146	1.0019	⚠ Yüksek Overfitting

Nihai Makine Öğrenmesi ve Klinik Bulgular Değerlendirmesi:

1. **Model Başarımı ve Kararlılık:** Gelişmiş veri setinde hiperparametre ayarlı ve örnek ağırlıklı yapılan modellemeler (özellikle **AdaBoost** ve **Random Forest**), hem yüksek R^2 skoru vermekte hem de overfitting gap'ini %10-20 aralığına düşürerek klinik açıdan son derece kararlı tahminler üretmektedir.
2. **Örnek Ağırlıklandırmanın Önemi:** Diyabetik hastalara 5 kat ceza ağırlığı verilmesi, modellerin anlık şeker dalgalanmaları yerine gerçek 3 aylık ortalamayı (HbA1c) daha doğru kavramasını sağlamıştır. Bu durum, teşhis aşamasında gözden kaçabilecek yüksek riskli hastaların tahmin hata payını (MAE) belirgin şekilde azaltmaktadır.
3. **Klinik Ödünleşim (Trade-off):** Diyabet hastalarını doğru tahmin etmeye odaklanıldığında genel R^2 skoru çok hafif gerilese de, diyabetik hasta MAE hatası %12-15 oranında iyileşmektedir. Tıbbi teşhis doğruluğu açısından bu takas son derece kabul edilebilir ve klinikte arzu edilen bir yaklaşımdır.